

서울 공공 자전거 이용자 수요 예측 프로젝트 발표

데이터 기반 수요 예측으로 운영 효율성 및 지속 가능성 개선

박예인(팀장), 서창환, 이원호, 김도철

2025

— 목차

01. 프로젝트 개요

05. 페르소나

09. 종합 결론

02. 프로젝트 목표 및 문제 정의

06. 데이터 수집 및 전처리

10. 향후 개선점 및 미래 로드맵

03. 팀 구성 및 역할

07. 데이터 분석 인사이트

11개발 환경

04. 프로젝트 일정

08. 웹 서비스 구현

프로젝트 개요

서울시 따릉이 이용량 지속 증가

연 100억 이상 적자 발생 문제

예산 부족, 재배치·유지보수 한계, 편의성 저하
위험

목표: 데이터 기반 수요 예측으로 운영 효율성 및
지속 가능성 개선

서울 공공 자전거 이용자 수요 예측 프로젝트



프로젝트 목표 및

문제 정의

①

문제 정의: 이용량 증가에도 불구하고 운영 효율성이 악화되는 원인은 무엇인가?

②

이용 패턴 분석 및 수요 예측 모델 구축으로
재배치·유지보수 최적화 방안 도출

③

글로벌 도시(뉴욕, 런던) 비교 분석을 통한 운영
효율성 및 지속 가능성 개선

운영상의 적자 규모 및 당면 과제

100억 +

연간 누적 적자 규모 (KRW)

효율성 위주의 운영 체질 개선 요구

연 300~350억 원의 운영 예산이 소요되고 있지만, 매년 100억 원 이상의 구조적 운영 적자가 계속되고 있습니다. 이는 과도한 현장 수작업 재배치 비용과 최적화되지 않은 부품 교체 주기에서 기인합니다.

팀 구성

박예인 (팀장)

전체 프로젝트 매니징 및 일정 관리. 시계열 데이터 가공 및 기상 요인, 계절적 이벤트 영향 분석의 메인 파이프라인 개발을 지휘했습니다.

이원호

이용 연령대별, 성별 세부 세그먼트를 발굴하고 최신 데이터 상에서 드러나는 청년 이용층 이탈 및 고령층 유입 추이를 집중 분석했습니다.

서창환

서울 따릉이 이용객들의 국내 거주자와 외국인 관광객 이용 패턴을 분리 탐색하고 시공간 수요 편차를 규명했습니다

김도철

미국 뉴욕(Citi Bike) 및 영국 런던(Santander Cycle) 등의 원시 데이터를 수집 및 표준화하여 글로벌 지표 격차를 비교 분석했습니다

프로젝트 일정

1단계

5/21~5/27

DB 수집 및 데이터 확보

3단계

6/4~6/7

대시보드 구현 및 UI
개발

2단계

5/28~6/3

데이터 전처리 및 모델
학습

4단계

6/8~6/11

최종 배포 및 발표 준비

프로젝트 일정

18	19	20	21 조별 주제,팀명 정하기	22 팀원별 주제 분배 및 DB 모으기
25 부처님오신날 대체 휴일	26 각자DB 모으기	27 모은 DB 전처리	28 DB 병합	29 시계열 파생변수 생성및 스케일링
1 모델 1 학습	2 모델2학습	3 지방선거일	4 머신러닝 확인	5 양상블 및 평가
8 대시보드 만들고 ui배치	9 코렘 + ngrok 등 확인.	10 버그확인 및 픽스	11 HuggingFace Space에 배포	12

페르소나

2030 직장인/학생, 평일 출퇴근 및 등하교
필수 이용

기상 영향 및 자전거 관리 품질에 민감한
반응

예시: 마이클 (26세, 미국인 대학 교환학생,
따릉이 매일 통학 이용)

서울 공공 자전거 이용자 수요 예측 프로젝트



페르소나

주말 한강, 고궁, 명동 등 관광지 중심으로
자전거 이용 집중
계절 및 날씨 변화에 따른 이용량 편차가
크게 나타남
외국인 관광객 및 국내 여가 이용자의
단거리·순환 경로 선호

서울 공공 자전거 이용자 수요 예측 프로젝트




데이터 수집 및 전처리



공공 자전거 데이터 수집
파리기, 뉴욕 **Citi Bike**, 런던 **TfL** 등
다양한 공공 자전거 데이터 수집




시계열 파생변수 생성
시간대, 요일, 계절 등 파생변수 생성
및 스케일링 처리



DB 병합 및 통합
다중 소스 데이터 정제 후 분석용
통합 **DB** 구축

데이터 수집 및



서울 공공 자전거 이용자 수요 예측 프로젝트

데이터 수집 및

```
def train_test_split_time(X, y, test_size=6):
    return X[:-test_size], X[-test_size:], y[:-test_size], y[-test_size:]

def train_models(X: np.ndarray, y: np.ndarray, n_trials: int = 50) -> dict:
    """
    1) Optuna로 각 모델 튜닝
    2) 전체 데이터로 최종 모델 재학습
    3) Holdout 6개월로 앙상블 가중치 최적화
    """
    X_tr, X_te, y_tr, y_te = train_test_split_time(X, y, test_size=6)

    # — 튜닝 —
    params_x, _ = tune_model("xgb", X_tr, y_tr, n_trials)
    params_l, _ = tune_model("lgb", X_tr, y_tr, n_trials)
    params_c, _ = tune_model("cat", X_tr, y_tr, n_trials)

    # — 전체 데이터 재학습 (train + test 모두) —
    xgb = build_model("xgb", params_x); xgb.fit(X_tr, y_tr)
    lgb = build_model("lgb", params_l); lgb.fit(X_tr, y_tr)
    cat = build_model("cat", params_c); cat.fit(X_tr, y_tr)
```

```
def classic_fit_predict(monthly_feat_df, lgb_n, xgb_n, ridge_a, lasso_a):
    """
    Train: 2023~2024, Val: 2025 (12 months)
    Final: 2023~2025
    Predict: 2026 (12 months)
    returns:
        val_preds(dict), metrics(dict), pred_2026(dict), y_val(12)
    """
```

```
# ✅ STEP 6: 앙상블
ens_2026, weights = weighted_ensemble(pred_2026, metrics)

if ens_2026 is None:
    ens_2026 = pred_2026.get("LightGBM", np.zeros(12))

city_2026_ens[city] = ens_2026
city_2026_by_model[city] = pred_2026
```

주요 데이터 분석 인사이트 ①

시간대별·요일별 이용 패턴 분석 및 서울·뉴욕·런던 도시 간 수요 비교

시간대별

평균 수요

- 피크 시간대 (출근): 오전 8시
- 피크 시간대 (퇴근): 오후 6시
- 최저 시간대: 새벽 3~4시
- 출퇴근 시간대에 수요 집중
- 평일 출근 피크가 퇴근 피크보다 뚜렷
- 주말은 오후 12~3시에 완만한 피크 형성
- 야간(22시 이후) 수요는 평일 대비 주말이 높음

요일별 평일 vs

주말 이용 패턴


- 평일 이용량이 주말 대비 평균 약 1.5배 높음
- 월요일~금요일: 출퇴근 목적 이용 집중
- 토·일요일: 여가·관광 목적 이용 비중 증가
- 수요일 이용량이 평일 중 최고
- 금요일 저녁 이용량 특이 증가
- 주말 한강·고궁 인근 대여소 집중

서울·뉴욕·런던

도시 간 비교

- 서울: 출퇴근 피크 가장 뚜렷, 전체 수요 최고
- 뉴욕: 피크 분산, 관광·여가 이용 비중 높음
- 런던: 전반적으로 완만한 수요 곡선
- 서울 평일 피크 집중도: 타 도시 대비 약 2배
- 런던은 연중 이용량 변동폭 가장 작음
- 뉴욕은 주말 심야 이용 비율이 가장 높음
- 세 도시 모두 기상 요인이 수요에 유의미한 영향

주요 데이터 분석 인사이트 ①




서울 공공 자전거 이용자 수요 예측 프로젝트

주요 데이터 분석 인사이트 ①


데이터 shape: (69190, 12)
도시: ['london' 'nyc' 'seoul']
컬럼: ['도시', '날짜', '시간', '요일', '주말여부', '계절', '연도', '월', '자전거수요', 'temperature', 'precipitation', 'wind_speed']

	도시	날짜	시간	요일	주말여부	계절	연도	월	자전거수요	temperature	precipitation	wind_speed
0	london	2023-01-01	0	6	1	winter	2023	1	808	NaN	NaN	NaN
1	london	2023-01-01	1	6	1	winter	2023	1	990	NaN	NaN	NaN
2	london	2023-01-01	2	6	1	winter	2023	1	655	NaN	NaN	NaN
3	london	2023-01-01	3	6	1	winter	2023	1	426	NaN	NaN	NaN
4	london	2023-01-01	4	6	1	winter	2023	1	248	NaN	NaN	NaN




서울 공공 자전거 이용자 수요 예측 프로젝트

주요 데이터 분석 인사이트 ①





서울 공공 자전거 이용자 수요 예측 프로젝트


주요 데이터 분석 인사이트 ①



주요 데이터 분석 인사이트 ①



주요 데이터 분석 인사이트 ①



주요 데이터 분석 인사이트 ①



주요 데이터 분석 인사이트 ①

Optuna 하이퍼파라미터 손잡이 + 앙상블 학습 ↗

XGBoost 중...

모델 성능 (홀드아웃 6개월)

XGB 맵	LGB 지도	고양이 지도	앙상블 MAPE
11.87%	10.46%	9.99%	9.99%

Optuna 하이퍼파라미터 손잡이 + 앙상블 학습

꼭!

모델 성능 (홀드아웃 6개월) ↗

XGB 맵	LGB 지도	고양이 지도	앙상블 MAPE
18.51%	15.58%	8.70%	8.72%

Optuna 하이퍼파라미터 손잡이 + 앙상블 학습

XGBoost 중...

모델 성능 (홀드아웃 6개월)

XGB 맵	LGB 지도	고양이 지도	앙상블 MAPE
9.97%	21.31%	15.05%	9.52%

↑ RMSE 499,767

주요 데이터 분석 인사이트 ②

계절별 자전거 수요 변화 및 주요 Feature 상관관계 분석 결과

계절별 수요 변화

봄 (3~5월): 수요 급증, 최고 이용 시즌
여름 (6~8월): 높은 수요 유지, 폭염 시 소폭 감소
가을 (9~11월): 안정적 수요, 쾌적한 날씨 영향
겨울 (12~2월): 수요 최저, 한파·강설 시 급감
서울 계절 진폭이 뉴욕·런던 대비 가장 크게
나타남

Feature 상관관계 히트맵

기온(temp): 수요와 강한 양의 상관관계 ($r \approx 0.72$)
강수량(rainfall): 수요와 음의 상관관계 ($r \approx -0.45$)
습도(humidity): 약한 음의 상관관계
풍속(windspeed): 미미한 영향
시간(hour): 피크 시간대와 강한 상관 ($r \approx 0.68$)
공휴일 여부: 이용 패턴 역전 현상 확인

시간·요일·도시 간 상관관계

시간대: 출퇴근(08시, 18시) 피크와 수요 상관
최고
요일: 평일 vs 주말 이용 패턴 뚜렷하게 구분
서울: 시간 상관계수 0.68, 요일 0.54
뉴욕: 시간 상관계수 0.61, 요일 0.49
런던: 시간 상관계수 0.57, 요일 0.43
도시별 패턴 유사하나 서울 진폭이 가장 큼

외국인 이용자 분석


외국인 입국자 수와 자전거 대여·반납 수요 간
상관관계 분석 결과, 거의 무상관(상관계수 ≈ 0)으로
나타남

외국인 이용자는 주말·관광지 중심 단기 이용
패턴으로 내국인과 뚜렷이 구별됨

계절 및 날씨보다 관광 일정·지역 접근성이 외국인
이용의 주요 결정 요인으로 분석됨






주요 데이터 분석 인사이트 ②





서울 공공 자전거 이용자 수요 예측 프로젝트







주요 데이터 분석 인사이트 ②




주요 데이터 분석 인사이트 ②





주요 데이터 분석 인사이트 ②






주요 데이터 분석 인사이트 ②




주요 데이터 분석 인사이트 ②



주요 데이터 분석 인사이트 ②



주요 데이터 분석 인사이트 ②



주요 데이터 분석 인사이트 ②



서울 공공 자전거 이용자 수요 예측 프로젝트



2025년 따릉이 이용객의 감소

- 2024년에는 전체적으로 증가 했지만 2025년시점에서는 전체적으로 감소
- 70대와 60대는 2025년에도 사용자가 증가하는 추세지만 작년에 비해 증가치가 줄고 이용자수가 적어 증가치가 미미함
- 주고객층이었던 20대의 빠른이탈 가장 이용자 비율이 높았던 20대가 -21.5%로 가장 격렬하게 하강
- 다음으로 감소비율이 큰 연령대는 10대로 -17.4%로 큰 감소치를 보임
- 20대 다음으로 사용비율이 높던 30대또한 -10.7%로 감소하여 젊은층의 이탈이 가시화됨 연령대에 따른 사용 순위
- 2025년 기준으로 30대>20대>40대>50대>10대>60대>70대이상>10대미만 순으로 이용자 수가 많음
- 2023~2025년동안 순위가 변한건 20대와30대 뿐으로 20대는 2023~2024년동안 1위였으나 2025년에 크게 하락해 2위가 됨

주요 데이터 분석 인사이트 (

연령별 시간대차이

- 남성 **10대** 미만의 경우는 저녁의 상승폭이 유달리 높고 아침의 상승폭이 비교적 낮음 다만 남성 **10대**미만은 사용량이 가장 낮은 비율이라 이상치의 영향을 크게 받는 점을 감안해야함
- 20대**는 밤과 새벽 시간대의 사용률이 비교적 크게 관측됨
- 10대**의 경우는 오후의 상승이 **4시**에 가장 높은점을 찍음 다른 연령대가 **5~6시**에 가장높은 점을 찍는것과 비교하면 특이한 점 하교시간이 퇴근시간보다 빠른 영향으로 보임 또한 저녁에 한번 피크치에 도달하면 아침이 되기 까진 지속적으로 하락하는 다른 연령대와 달리 **8시부터** 다시 상승치를 보인다
- 10시**전에 하락세로 변하는 특이한 형태를 보임
- 아침과 저녁에 크게 상승하강하는 수치는 **50대**부터 조금식 줄어든다 **60대**부터 크게 완만해짐
- 새벽시간대의 사용률은 남성이 여성에 비해 확연히 많은 사용률을 보이나 **70대**이상의 여성은 남성의 평균치보다 사용률이 크며 반대로 **70대**이상의 남성은 새벽 이용률이 가장 저조해 **0**시기준으로 **70대**이상 여성의 절반이하의 수치를 보임






주요 데이터 분석 인사이트 ②









기본적으로 남성 사용자 수가 여성 사용자에 비해 높으며
밤과 새벽시간대 일수록 남성의 비율이 늘고 여성의
비율이 줄어드는 식으로 차이가 벌어지고 있음
사용자비율이 지속적으로 남성이 늘어나고 여성이
줄어들고
있음 20대 사용자의 이탈이 가속화 하고 있는 가운데
여성사용자의 20대비율이 남성에 비해 큰것또한
이유로 추측됨

주요 데이터 분석 인사이트 ②



서울 공공 자전거 이용자 수요 예측 프로젝트

주요 데이터 분석 인사이트 ②



서울 공공 자전거 이용자 수요 예측 프로젝트

도시별 자전거 수요 비교

서울, 뉴욕, 런던의 월별
이용량 추이를
비교합니다. 서울이 가장
높은 수요를 보이며,
런던이 최저 수요를
기록합니다. 2023~2026년
예측치 포함.

항목	서울 (따릉이)	뉴욕 (Citi Bike)	런던 (Santander)
월 평균 이용량	최고 수준	중간 수준	최저 수준
피크 시즌	봄·가을 (4~5월, 9~10월)	여름 (6~8월)	여름 (6~8월)
2023 이용량 추이	지속 증가	완만한 증가	완만한 증가
2026 예측 수요	대폭 증가 예상	소폭 증가 예상	유지 또는 소폭 증가
계절 편차	매우 큼 (겨울 급감)	중간	낮음

머신러닝 모델 성능 비교 ①

분류 모델(LSTM, DNN, LightGBM)의 정확도(Acc) 및 F1 점수를 비교하여 최적 모델을 도출합니다.
(뉴욕,런던,서울)

모델	정확도 (Acc)	F1 점수 (Macro)	비고
LSTM	93.6%	0.937	시계열 특화, 순차 패턴 학습
DNN	87.9%	0.879	범용 딥러닝, 빠른 학습
LightGBM	94.5%	0.946	최고 성능, 트리 기반 앙상블

머신러닝 모델 성능 비교 ②

회귀 모델 및 앙상블 결과 비교.
Optuna 하이퍼파라미터 튜닝을
통해 최적 모델을 선정하고,
앙상블 기법으로 예측 정확도를
향상시켰습니다.

모델	MAE	MAPE	비고
LightGBM	12.4	8.3%	베이스라인
DNN	11.8	7.9%	기본 튜닝
LightGBM + Optuna	9.2	6.1%	하이퍼파라미터 최적화
앙상블 (최종)	7.6	4.8%	최고 성능

머신러닝 모델 성능 비교 ③

모델	MAE	RMSE	비고	정확도
Linear Regression	45.2	50.4	기본 통계 모델, 기준점 제공	61.0%
Random Forest	28.4	33.5	앙상블 베깅 모델, 과적합 방지 및 안정적	82.0%
XGBoost	22.1	27.9	균형 잡힌 부스팅, 높은 예측력 제공	89.0%
LightGBM	20.5	26.7	최고 성능,빠른 학습 및 대용량 데이터 특화	91.0%

웹 서비스 구현

서울 공공 자전거 이용자 수요 예측 프로젝트



종합 결론



수요 예측 정확도 향상
LSTM·LightGBM 앙상블로 높은
예측 성능 달성



글로벌 운영 인사이트
서울·뉴욕·런던 비교를 통한 운영
효율화 방향 도출



맞춤 운영 전략
이용 패턴별 재배치·유지보수
최적화 전략 제시

향후

개선점 및

미래

로드맵

①

데이터 정확도 향상: 실측 데이터 확대 및 결측치 보완으로 예측 모델의 신뢰도 제고

②

실시간 수요 반영 시스템 개발: 실시간 데이터 파이프라인 구축 및 동적 수요 예측 자동화

③

이용자 편의성 강화 및 신규 기능 추가: 맞춤형 추천 기능, UI 개선 및 다국어 서비스 확대

개발 환경 및 마무리

기술 스택 및 배포 환경 소개 · Q&A

언어 및 분석

PYTHON (PANDAS, NUMPY, SCIKIT-LEARN)

ML 프레임워크

LIGHTGBM · LSTM · DNN · OPTUNA

배포 환경

HUGGINGFACE SPACE (웹 대시보드)

Q&A

발표를 들어주셔서 감사합니다!

감사합니다

Q&A 및 질의응답

서울 공공 자전거 이용자 수요

예측

박예인 · 서창환 · 이원호 · 김도철